

דוח סיכום: גילוי ועקיבה אובייקטים קטנים

מסנזור תרמי בתנועה

1. רקע

הפרויקט עוסק בבעיה מתחום הראייה הממוחשבת: גילוי ועקיבה (Detection and Tracking) אחר אובייקטים קטנים מסוג אדם ורכב, הנקלטים מסנזור תרמי המותקן על גבי כלי טיס בלתי מאויש (רחפן). המערכת נדרשת לפעול במתאר אנכי, בגבהים משתנים (100 עד 500 מטרים), ובזמן שהסנזור עצמו נמצא בתנועה מתמדת.

המטרה המבצעית היא "אחיזת שטח" – היכולת לסרוק שטח נרחב ככל האפשר מגובה רב, ועדיין לזהות תנועות חשודות על הקרקע.

1.1 אתגרי הבעיה

פתרון הבעיה כרוך בהתמודדות עם מספר אתגרים משמעותיים:

1. **אובייקטים קטנים:** ככל שהרחפן עולה גבוה יותר, כך האובייקטים על הקרקע (אנשים, כלי רכב) נראים קטנים יותר בתמונה. לעיתים, גודלם הוא עשרות בודדות של פיקסלים, מה שמקשה על זיהוי המבוסס על צורה או מאפיינים ויזואליים מורכבים.
2. **סנזור בתנועה:** הרחפן אינו סטטי. הוא נע, רועד ומשנה את זווית הצילום שלו. תנועה זו גורמת לכל הרקע בתמונה לזוז, ומקשה מאוד על ההבחנה בין תנועת הרקע (הנובעת מתזוזת המצלמה) לבין תנועה אמיתית של אובייקט על הקרקע.
3. **רעש תרמי:** תמונות תרמיות רגישות לתנאי הסביבה. תנודות טמפרטורה באוויר (Turbulence) יכולות ליצור עיוותים ורעשים מקומיים בתמונה, הנראים כ"ריצודים" או "אדוות חום", שעלולים להיות מזוהים בטעות כתנועה.
4. **אילוצים טכניים:**
 - 4.1. **ללא מודלים עמוקים:** הפתרון נדרש להתבסס על טכניקות "קלאסיות" של עיבוד תמונה וראייה ממוחשבת, ללא שימוש ברשתות נוירונים עמוקות.
 - 4.2. **ללא אימון:** נאסר לבצע תהליך אימון על דאטה ייעודי של הבעיה. הפתרון חייב להיות גנרי מספיק כדי לעבוד "מהקופסה".
 - 4.3. **זמן אמת:** האלגוריתם חייב להיות יעיל חישובית ולאפשר עיבוד של לפחות 10 פריימים לשנייה (10fps) כדי שיוכל לעבוד במכשיר קצה.

2. גישות שנבחנו

במהלך המחקר והפיתוח, נבחנו מספר גישות לפתרון האתגרים. ניתן לחלק את הבעיה לשתי תתי-בעיות מרכזיות: **זיהוי (Detection)** – מציאת אובייקטים מעניינים בפריים בודד, **ועקיבה (Tracking)** – קישור הזיהויים לאורך זמן ליצירת מסלול תנועה עקבי.

2.1. גישות לייצוב תמונה וזיהוי אובייקטים

גישה ראשונית (נדחתה): זיהוי מבוסס שינוי מקומי ופיצ'רים

הגישה הראשונית שהוצעה התבססה על זיהוי שינויים מקומיים לאורך זמן. הרעיון היה לחלק את התמונה לאזורים קטנים (patches) ולחשב מדד "השתנות" עבור כל אזור בין פריימים עוקבים. אזורים עם השתנות חריגה (גבוהה מאוד או נמוכה מאוד ביחס לחציון) יסומנו כמועמדים לזיהוי. לאחר מכן, תוכנן להשתמש בטכניקות כמו Maximally Stable Extremal Regions (MSER) לאיתור "נקודות חמות" (blobs) ולבסוף לסנן אותן באמצעות איתור פיצ'רים ויזואליים (כמו SIFT) בתוך האזורים החשודים.

מדוע גישה זו אינה מתאימה?

1. **רגישות לתנועת המצלמה:** ללא הבנה ותיקון של תנועת המצלמה הגלובלית, כל פיקסל בתמונה זז. כתוצאה מכך, מדד "השתנות" מקומי יהיה גבוה כמעט בכל מקום, והמערכת תתקשה מאוד להבדיל בין תנועת רקע לתנועת אובייקט אמיתי. היא הייתה עלולה לזהות בטעות עצים, בניינים או כבישים כאובייקטים בתנועה.
2. **קושי בהתמודדות עם רכבים סטטיים:** הגישה הניחה שרכבים שאינם בתנועה יהיו "קרים" ולא יזוהו. הנחה זו אינה תמיד נכונה, וחשוב מכך, הגישה הייתה מתקשה לעקוב אחר רכב שנעצר באופן זמני.
3. **מורכבות וריבוי פרמטרים:** הגישה דרשה כיוול עדין של ספים רבים (סף השתנות, פרמטרים של MSER וכו'), מה שהופך אותה לפחות רובסטית.

גישות נוספות ליישור תמונה (נדחו)

במהלך החיפוש אחר פתרון לייצוב התמונה, נבחנו שתי שיטות נוספות שלא התאימו:

1. **Enhanced Correlation Coefficient (ECC):** זוהי שיטה איטרטיבית למציאת טרנספורמציה אפינית או פרספקטיבית שממקסמת את הקורלציה בין שתי תמונות. למרות שהיא יכולה להיות מדויקת, היא נפסלה משתי סיבות עיקריות: **זמן ריצה גבוה**, הנובע מאופייה האיטרטיבי, שלא איפשר עמידה בדרישת ה-10fps; ו**דיוק נמוך** במקרים של תנועה גדולה או שינויי תאורה משמעותיים בין פריימים, תנאים שנפוצים בסרטונים מהרחפן.
2. **Stereo Rectification:** טכניקה זו נועדה ליישר זוג תמונות שצולמו משתי נקודות מבט שונות (כמו במערך סטריאו), כך שקווי הסריקה (epipolar lines) יהיו מקבילים. מטרתה העיקרית היא להקל על חישוב מפת עומק (disparity map). שיטה זו אינה מתאימה לבעיית ייצוב וידאו מכיוון שהיא יוצרת **ייחוס חדש עבור כל זוג פריימים**. כדי להשתמש בהסרת רקע, אנו זקוקים למרחב **ייחוס אחיד וקבוע** (זה של הפריימים הראשון) שאליו כל הפריימים מיושרים. יישור כל פריימים לקודמו במרחב חדש ונפרד מונע בניית מודל רקע עקבי לאורך זמן.

גישה נבחרת: זיהוי מבוסס ייצוב תמונה והסרת רקע

הגישה שנבחרה מתמודדת ישירות עם האתגר המרכזי – תנועת המצלמה. במקום לנסות לזהות תנועה בעולם "רועד", הגישה הראשונה מייצבת את התמונה באופן וירטואלי, כך שהרקע הסטטי (אדמה, כבישים, מבנים) ייראה כאילו אינו זז כלל. רק לאחר שלב הייצוב, ניתן בקלות לזהות אובייקטים שבאמת

זזים ביחס לרקע.

מדוע גישה זו מתאימה?

1. **פתרון ישיר לבעיה המרכזית:** היא מנטרלת את ההשפעה של תנועת הסנסור, שהיא המקור המרכזי לקושי בבעיה.
2. **הפרדה ברורה:** לאחר הייצוב, כל פיקסל שעדיין מראה שינוי משמעותי לאורך זמן הוא בהכרח חלק מאובייקט שזז באופן עצמאי על הקרקע. זה מפשט דרמטית את שלב הזיהוי.
3. **רובסטייות:** השיטה פחות תלויה בצורה, בגודל או בטמפרטורה המדויקת של האובייקט, ויותר בתכונת התנועה שלו בעולם האמיתי.

2.2 גישות לעקיבה

גישה ראשונית (נדחתה): Particle Filter

ההצעה הראשונית הייתה להשתמש ב-Particle Filter. זהו אלגוריתם עקיבה בייסיאני שמייצג את ההתפלגות של מצב האובייקט על ידי "ענן" של חלקיקים (דגימות). כל חלקיק מייצג השערה לגבי מצב האובייקט (מיקום, מהירות). יעילותו תלויה במידה רבה בשלב המדידה, שבו לכל חלקיק מחושב משקל על פי **פונקציית ה-Likelihood** – הסבירות לקבל את המדידה הנוכחית (ה-detection) בהינתן מצב החלקיק.

מדוע גישה זו אינה מתאימה?

1. **קושי בעקיבה אחר אובייקטים מרובים (MOT):** אלגוריתם ה-Particle Filter סטנדרטי מיועד לעקיבה אחר אובייקט יחיד. כדי לעקוב אחר מספר אנשים ורכבים בו-זמנית, נדרש להרחיב את האלגוריתם באופן משמעותי (למשל, להריץ פילטר נפרד לכל אובייקט ולפתור בעיית התאמה מורכבת) או להשתמש בגרסאות מסובכות יותר, מה שפוגע ביעילות החישובית.
2. **מורכבות חישוב ה-Likelihood:** בניגוד לפילטר קלמן, שמניח רעש גאוסיאני, פילטר חלקיקים דורש הגדרה מפורשת של פונקציית ה-Likelihood. הגדרת פונקציה כזו, שתהיה גם מדויקת וגם מהירה לחישוב, היא אתגר בפני עצמו, במיוחד כשהאובייקטים קטנים וחסרי מאפיינים ברורים.

גישה נבחרת: Kalman Filter (במימוש SORT)

הפתרון שנבחר הוא להשתמש באלגוריתם (SORT) Simple Online and Realtime Tracking, אשר מבוסס על **פילטר קלמן (Kalman Filter)** והאלגוריתם **ההונגרי** להתאמה.

מהו פילטר קלמן? זהו אלגוריתם רקורסיבי יעיל מאוד שמעריך את המצב של מערכת דינמית מתוך סדרה של מדידות רועשות. בהקשר שלנו, "המצב" הוא המיקום והמהירות של האובייקט, ו"המדידות" הן הזיהויים (Bounding Boxes) שמתקבלים משלב הזיהוי בכל פריים. הפילטר מבצע שני שלבים בכל פעם: **חיזוי** – מנבא היכן האובייקט צפוי להיות בפריים הבא על סמך מהירותו **ועדכון** – מתקן את החיזוי על סמך המיקום הנמדד החדש.

מדוע גישה זו מתאימה?

1. **יעילות חישובית:** פילטר קלמן הוא מהיר מאוד ומתאים ליישומי זמן אמת.
2. **טיפול מובנה ב-MOT:** אלגוריתם SORT משלב את פילטר קלמן עם מנגנון התאמה יעיל (מבוסס IOU - Intersection over Union), המאפשר לשייך זיהויים חדשים למסלולי עקיבה קיימים או ליצור מסלולים חדשים. הוא מנהל ביעילות את הופעתם והיעלמותם של אובייקטים מרובים.
3. **רובסטינות ל-occlusions:** אם אובייקט לא זוהה בפריים מסוים (למשל, הוסתר לרגע), פילטר קלמן יכול להמשיך ולחזות את מיקומו למספר פריימים, מה שמאפשר "לגשר" על פערים קצרים בזיהוי.
4. **מודל תנועה פשוט:** אלגוריתם SORT משתמש במודל תנועה לינארי במהירות קבועה, שהוא פשוט, יעיל, ועובד היטב לחיזויים קצרי טווח הנדרשים בין פריימים עוקבים.

3. הפתרון

הפתרון שנבחר הוא Pipeline רב-שכבתי, כאשר כל שכבה אחראית על שלב אחר בעיבוד.

3.1 מילון מושגים טכניים

לפני פירוט השלבים, נסביר מספר מושגי מפתח:

1. **Optical Flow (זרימה אופטית):** טכניקה לניתוח תנועה בין שני פריימים עוקבים. היא מחשבת וקטור תזוזה עבור כל פיקסל או עבור קבוצת פיקסלים.
2. **Harris Corners:** אלגוריתם לאיתור "פינות" בתמונה. פינות הן נקודות עניין (features) טובות למעקב.
3. **Lucas-Kanade Optical Flow:** שיטה "דלילה" (Sparse) לחישוב זרימה אופטית. היא מחשבת את התנועה רק עבור קבוצת נקודות עניין נבחרת, מה שהופך אותה למהירה משמעותית.
4. **Homography (הומוגרפיה):** טרנספורמציה גיאומטרית (מטריצה של 3×3) הממפה נקודות ממישור אחד למישור אחר. בהקשר שלנו, היא משמשת כדי "לעוות" את הפריים הנוכחי כך שיראה כאילו צולם מאותה נקודת מבט בדיוק כמו פריים ייחוס.
5. **Morphological Operations (פעולות מורפולוגיות):** סט של פעולות עיבוד תמונה על תמונות בינאריות (שחור/לבן), כגון Erosion (שחיקה), Dilation (הרחבה), Opening (מסיר רעש קטן) ו-Closing (סוגר חורים באובייקטים).

3.2 שלבי האלגוריתם

האלגוריתם מורכב מהשלבים הבאים, המופעלים סדרתית על כל פריים מהווידאו:

שלב 1: ייצוב תנועת המצלמה (Motion Stabilization)

זהו השלב הקריטי ביותר. מטרתו היא לבטל את תנועת הרחפן וליצור וידאו וירטואלי שבו הרקע סטטי.

1. **מציאת נקודות עניין:** על כל פריים נכנס, האלגוריתם מזהה נקודות עניין יציבות באמצעות `cv2.goodFeaturesToTrack`.

2. **חישוב Optical Flow:** באמצעות אלגוריתם Lucas-Kanade, המערכת עוקבת אחר התזוזה של נקודות העניין מהפריים הקודם לפריים הנוכחי.

3. **חישוב הומוגרפיה מצטברת:**

3.1. המערכת מחשבת הומוגרפיה H_t בין הפריים הנוכחי לקודם, על בסיס תזוזת

הנקודות. כדי להתמודד עם שגיאות מעקב, נעשה שימוש ב-RANSAC, אלגוריתם שמוצא את ההתאמה הטובה ביותר תוך התעלמות מנקודות חריגות (outliers).

3.2. הומוגרפיה זו מוכפלת בהומוגרפיה המצטברת מהשלב הקודם $H_{new} = H_{old} \cdot H_t$.

כך, המערכת שומרת טרנספורמציה כוללת שמיישרת את הפריים הנוכחי ישירות לפריים הראשון בסרטון.

4. **הפעלת ההומוגרפיה (Warping):** הפריים הנוכחי "מעוות" באמצעות מטריצת ההומוגרפיה המצטברת H , כך שהרקע בו יתיישר עם הרקע של הפריים הראשון.

5. **תיקון עדין והחלקה (EMA):** עקב הצטברות שגיאות קטנות, היישור הישיר לפריים הראשון עלול ליצור "רעידות" קלות. כדי לפתור זאת, מופעל שלב תיקון נוסף:

5.1. מחושבת טרנספורמציה אפינית A_t נוספת, הפעם בין הפריים שכבר עבר

warping לבין הפריים הראשון המקורי.

5.2. במקום להפעיל את התיקון A_t ישירות, הוא מוחלק לאורך זמן באמצעות

ממוצע נע אקספוננציאלי (EMA) המחושב כך:

$$A_{new} = \alpha A_{old} + (1 - \alpha) A_t$$

הצדקה לשיטת חישוב ההומוגרפיה: הבחירה לחשב הומוגרפיה בין פריימים עוקבים H_t ולהצמיד אותה

למטריצה מצטברת, במקום לחשב הומוגרפיה ישירות מהפריים הנוכחי לפריים הראשון, היא החלטה קריטית. חישוב ישיר לפריים הראשון הופך לבעייתי ככל שמתקדמים בסרטון. הפער הוויזואלי בין הפריים הנוכחי לפריים הראשון גדל, מספר נקודות העניין המשותפות קטן, והסיכוי להתאמה שגויה עולה. הדבר מוביל להומוגרפיה רועשת ולא יציבה. הגישה שנבחרה, של צבירת טרנספורמציות קטנות ומדויקות יותר (בין פריימים סמוכים הדומים זה לזה), מונעת את הצטברות הרעש. מכיוון שהומוגרפיה היא טרנספורמציה לינארית, ניתן לשרשר אותן על ידי כפל מטריצות. התוצאה הסופית $H_{final} = H_1 \cdot \dots \cdot H_{t-1} \cdot H_t$ שקולה מתמטית להומוגרפיה הישירה מהפריים האחרון לראשון, אך היא מתקבלת בתהליך יציב רובסטי הרבה יותר.

שלב 2: סינון רעשים ועיבוד מקדים

לאחר שהווידאו יוצב, מופעלות מספר שכבות סינון על הפריים המיוצב כדי להכין אותו לזיהוי.

1. **פילטר חציון בזמן (Temporal Median Filter):** פילטר זה שומר חמישה פריימים אחרונים

(עם דילוג, מטעמי יעילות) ומחשב עבור כל פיקסל את ערך החציון שלו לאורך ציר הזמן.

פעולה זו "מנקה" ביעילות את רעש ה-turbulence (ריצודים תרמיים) מבלי לטשטש את האובייקטים עצמם.

2. **(Band-Pass Filter):** פילטר זה מסיר תדרים נמוכים מאוד (שינויים הדרגתיים וגדולים

בתמונה) ותדרים גבוהים מאוד (רעש של פיקסלים בודדים). מה שנותר הם האובייקטים בגודל בינוני, שהם בדיוק מטרות העניין שלנו.

שלב 3: זיהוי תנועה (Detection)

1. **החסרת רקע (Background Subtraction):** על הפריים המיוצב והמסונן, מופעל אלגוריתם BackgroundSubtractorKNN. אלגוריתם זה לומד עבור כל פיקסל מהו המראה ה"רגיל" שלו לאורך זמן. מכיוון שהרקע שלנו כעת סטטי, כל פיקסל שיוסמן כ"חזית" (foreground) שייך לאובייקט בתנועה. התוצאה היא מסיכה בינארית (שחור-לבן).
2. **חיתוך שוליים (Cropping):** תהליך הייצוב (warping) יוצר שוליים שחורים או מעוותים בקצוות התמונה. מופעלת מסיכת חיתוך דינמית שמסירה את השוליים הבעייתיים.
3. **פעולות מורפולוגיות:** על המסיכה הבינארית מופעלות פעולות Opening (להסרת נקודות רעש קטנות) ו-Closing (למילוי חורים קטנים בתוך אובייקטים). לבסוף, מופעלת פעולת Dilation עם גרעין רחב כדי לחבר חלקים קרובים של אותו אובייקט (למשל, גלגלי רכב לגוף הרכב).

שלב 4: סיווג ועקיבה

1. **מציאת קונטורים וסיווג פשוט:** האלגוריתם מוצא את כל הקונטורים (האזורים הלבנים המחוברים) במסיכה הסופית ומחשב את המלבן החוסם (Bounding Box) שלהם. לאחר מכן, מופעל מסווג פשוט מבוסס-חוקים על גודל ויחס גובה-רוחב של המלבן כדי להבחין בין רכב, אדם ורעש.
2. **עקיבה עם SORT:** רשימת המלבנים החוסמים המסווגים מועברת לאלגוריתם המעקב (SORT), אשר חוזה את מיקום האובייקטים, מתאים את הזיהויים החדשים למסלולים קיימים באמצעות מדד IOU, מעדכן את מצבם, ומנהל יצירה ומחיקה של מסלולים.

3.3. בחירת פרמטרים מרכזיים

הצלחת האלגוריתם תלויה בכיול נכון של מספר פרמטרים קריטיים, שנבחרו לאחר ניסוי וטעייה:

1. שכבת יצוב התנועה, נבחר פרמטר $\alpha = 0.975$ פרמטר זה שולט על מידת ההחלקה של טרנספורמצית התיקון. ערך קרוב ל-1 נותן משקל גבוה למצב הקודם, ויוצר ייצוב חלק מאוד על חשבון תגובה איטית לשינויים אמיתיים. הערך 0.975 נמצא כאיזון טוב בין החלקה לתגובתיות.
2. בשכבת פילטר ה־median, נבחר חלון היסטוריה של 5 פריימים כדי לספק מספיק דגימות לחישוב חציון יציב, בעוד שהדילוג (dilation) של 2 מאפשר "לראות" רחוק יותר בזמן מבלי לשמור ולעבד כל פריים, ובכך חוסך בזיכרון ובזמן ריצה.
3. גדלי הגרעינים לפעולות המורפולוגיות נבחרו בקפידה:
 - 3.1. **Opening - 3:** גרעין קטן יחסית להסרת רעש "מלח ופלפל" מבלי לפגוע באובייקטים קטנים אמיתיים.
 - 3.2. **Closing - 4:** גרעין מעט גדול יותר לסגירת חורים קטנים בתוך אובייקטים, כמו למשל בין הרגליים של אדם הולך.
 - 3.3. **Dilation 7, 9:** גרעין מלבני רחב יחסית, שנועד לחבר אזורים קרובים השייכים

לרכב (למשל, צללית הגוף והחתימה התרמית של המנוע או הגלגלים) לאובייקט אחד.

4. הפרמטרים של העקיבה: פרמטרים אלו שולטים בהתנהגות של אלגוריתם המעקב SORT:

4.1. $\max_age=35$: מספר הפריימים המרבי שמסלול עקיבה "יחכה" לזיהוי חדש לפני שהוא נמחק. ערך זה מאפשר להתמודד עם הסתרות קצרות (למשל, אדם שעובר מאחורי עץ) מבלי לאבד את ה-ID שלו.

4.2. $\min_hits=35$: מספר הזיהויים הרצופים הנדרש כדי שמסלול עקיבה יאושר ויוצג. סף גבוה זה מונע יצירת מסלולים קצרי-חיים כתוצאה מזיהויי שווא (False Positives).

4. מדידת השיטה וסיכום

על מנת למדוד את ביצועי הפתרון באופן כמותי ומדויק, יש להשתמש בתיוג ידני (Ground Truth). תיוגים אלה כוללים מיקומים מדויקים של האובייקטים לאורך זמן, מה שמאפשר להשוות את הפלט של האלגוריתם לנתוני אמת.

המדדים המקובלים בתחום מעקב אחר אובייקטים מרובים (Multiple Object Tracking - MOT) הם (MOTA) Multiple Object Tracking Accuracy ו- (MOTP) Multiple Object Tracking Precision.

המדדים MOTA ו-MOTP בוחנים היבטים שונים של ביצועי האלגוריתם, מה שהופך אותם למשלימים זה את זה.

4.1. מדד הדיוק: MOTA

מדד ה-MOTA מעריך את **דיוק הזיהוי וההתאמה** של האלגוריתם לאורך זמן. המדד מתייחס לשלושה סוגי שגיאות מרכזיים ומספק ציון יחיד המבטא את יכולת המערכת לשמור על מסלולים עקביים. הוא מחושב באופן הבא:

$$MOTA = 1 - \frac{\sum_t (FN_t + FP_t + IDSW_t)}{\sum_t GT_t}$$

1. FN_t : מספר האובייקטים האמיתיים שלא זוהו בפריים t .

2. FP_t : מספר הזיהויים השגויים של אובייקטים שלא קיימים בפועל בפריים t .

3. $IDSW_t$: מספר הפעמים שהמערכת החליפה מזהה (ID) בין מסלולים שונים בפריים t .

4. GT_t : מספר האובייקטים האמיתיים בפריים t .

המונה של הנוסחה הוא סכום של כל השגיאות לאורך כל הסרטון. המכנה הוא סך כל האובייקטים האמיתיים. התוצאה היא ציון בין $-\infty$ ל-1. ציון 1 מצביע על ביצועים מושלמים (אפס שגיאות), ואילו ציון נמוך

יותר מצביע על יותר שגיאות.

4.2 מדד הנכונות: MOTP

מדד ה-MOTP בוחן את הנכונות הממוצעת של המיקום של האובייקטים שחוזה האלגוריתם, ביחס למיקומם האמיתי. מדד זה מספק מידע על איכות הגיאומטרית של תיבות התוחם (Bounding Boxes) שהמערכת יצרה. הוא מחושב באופן הבא:

$$MOTP = \frac{\sum_{t,i} d_t^i}{\sum_t C_t}$$

1. d_t^i : מרחק המיקום או מידת ההתאמה (לדוגמה, Intersection over Union - IoU) בין הזיהוי שחוזה האלגוריתם לאובייקט ה- i לבין מיקומו האמיתי בפריים t .
2. C_t : מספר ההתאמות המוצלחות בפריים t .

המדד מחשב את הממוצע של כל שגיאות המיקום עבור כל האובייקטים שזוהו כראוי. ציון גבוה יותר ב-MOTP מצביע על כך שהאלגוריתם לא רק הצליח לזהות ולעקוב אחר האובייקטים, אלא גם הצליח למקם אותם בדיוק מרחבי גבוה.

לסיכום, בעוד ש-MOTA הוא מדד כללי לדיוק של כל שלבי העקיבה (זיהוי, החלפת מזהים), MOTP מתמקד באופן ספציפי בדיוק המיקומי של האובייקטים שזוהו. שילוב של שני המדדים מספק תמונה מלאה ומדויקת יותר של ביצועי האלגוריתם.

4.2 סיכום

בפרויקט הצגנו פתרון אפקטיבי ויעיל לבעיה המאתגרת של גילוי ועקיבה אחר אובייקטים קטנים מסנסור תרמי נע, תחת אילוצים של ריצה בזמן אמת וללא שימוש במודלים מאומנים.

ליבת הפתרון היא ההפרדה המוחלטת בין בעיית תנועת המצלמה לבעיית תנועת האובייקט. על ידי ייצוב חכם של התמונה בשלב הראשון, שלב זיהוי התנועה הופך לפשוט ורובוסטי באופן משמעותי. השילוב של טכניקות קלאסיות לעיבוד תמונה (סינון, מורפולוגיה) עם אלגוריתם עקיבה מודרני ויעיל (SORT מבוסס פילטר קלמן) מאפשר למערכת לעמוד בדרישות הביצועים וליצור תוצאות עקיבה עקביות ויציבות. תהליך הפיתוח, שכלל בחינה ופסילה של גישות חלופיות, הוביל לארכיטקטורה מודולרית וחזקה המתמודדת בהצלחה עם כלל האתגרים שהוגדרו.

לפרויקט יש פוטנציאל יישומי משמעותי במגוון רחב של תחומים, כולל ביטחון, חיפוש והצלה, וניטור סביבתי. הפתרון מאפשר יכולת אחיזת שטח רציפה ומגובה רב, וזיהוי תנועות חשודות על הקרקע. על ידי שימוש בשיטות יעילות ללא תלות במודלים מאומנים, הפתרון הוא גנרי וניתן ליישום במגוון רחב של

מכשירים ופלטפורמות קצה, גם כאלה עם כוח חישוב מוגבל. בכך, הפרויקט מהווה בסיס לפיתוח מערכות זיהוי מתקדמות, יעילות וחסכוניות, תוך שימור היכולת לזהות איומים או תנועות חשודות בתנאים מאתגרים.